

Fusión de Atención Cruzada para Segmentación del Segmento Anterior

Usando Representaciones de Imagen Complementarias

Caleb Alfaro Desireé Avilés Danilo Duque

Semana 17, 2026

Instituto Tecnológico de Costa Rica

Agenda

Motivación

Fundamentos

Trabajo Relacionado

Método Propuesto

Experimentos y Resultados

Conclusión

El Problema: Cataratas


- Las cataratas afectan a más de **100 millones de personas** en el mundo
- Es la **principal causa de ceguera prevenible**
- El diagnóstico requiere identificar estructuras del segmento anterior:
 - Córnea, pupila, cristalino

Necesidad clínica

Segmentar automáticamente estas estructuras para graduación, planificación quirúrgica y guía intraoperatoria.

¿Por qué RGB solo no es suficiente?

- La opacificación del cristalino genera **bajo contraste de color**
- Las lámparas de hendidura producen **artefactos de iluminación**
- Los modelos unimodales fallan precisamente cuando el paciente está más grave



Problema clave

El color solo no alcanza para delinear los bordes del cristalino opacificado.

¿Qué es Segmentación Multimodal?

Idea central

Usar **múltiples representaciones** de la misma escena y **fusionarlas** para que el modelo vea más de lo que cualquier vista individual puede capturar.

Multimodal clásico (sensores distintos):

- MRI T1 + T2 + FLAIR para tumores cerebrales
- RGB + profundidad para escenas 3D


Nuestro enfoque (misma imagen, dos vistas):

- Imagen RGB → features fotométricas
- Mapa de bordes Canny → features geométricas
- Espacios de features heterogéneos ⇒ fusión multimodal

¿Qué es U-Net?

Arquitectura **encoder-decoder** para segmentación:

- **Encoder:** reduce resolución, aumenta canales. Captura **qué** hay.
- **Decoder:** aumenta resolución, reduce canales. Recupera **dónde**.
- **Skip connections:** conectan encoder y decoder. **Preservan el detalle fino** que se pierde al submuestrear.



Clave

Usamos U-Net como backbone porque sus skip connections preservan los bordes anatómicos finos para segmentar córnea y cristalino.

¿Qué es el detector de bordes Canny?

Transforma una imagen a color en un **mapa de bordes**.

1. **Suavizar**: filtro Gaussiano para eliminar ruido.
2. **Gradiente**: en cada píxel, qué tan rápido cambia el brillo.
3. **Adelgazar**: solo los máximos locales en la dirección del gradiente.
4. **Conectar bordes** con dos umbrales ($t_1 = 50$, $t_2 = 150$):
 - $> t_2$: borde fuerte (se queda)
 - $< t_1$: se descarta
 - Entre t_1 y t_2 : solo si conecta a un borde fuerte

Dos umbrales producen bordes **limpios y conectados**: eliminan ruido pero mantienen contornos relevantes.

¿Qué es Atención (Attention)?

Mecanismo que permite a un modelo **enfocarse** en las partes relevantes.

Tres componentes:

- **Q (Query):** “¿qué información necesito?”
- **K (Key):** “¿qué información tengo?”
- **V (Value):** “el contenido que voy a entregar”

Cálculo: se compara Q con cada K, se obtiene un peso de relevancia y se combinan los V.

Analogía


Como buscar en Google: tu **consulta** (Q) se compara con **claves** (K) de páginas web y recibes los **contenidos** (V) más relevantes.

$$\text{Atención}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d}}\right) V$$

Self-Attention vs Cross-Attention

Self-Attention


Misma entrada -



Ej: "I love cats" →
cada palabra se atiende a sí misma

Cross-Attention

Entrada A -



Ej: nuestro modelo
RGB → Q, Bordes → K,V

En nuestro modelo


El encoder RGB genera **Q**, el encoder de bordes genera **K** y **V**. Los features RGB “preguntan” dónde están los bordes y enriquecen su representación.

Trabajo Relacionado: Segmentación Médica


- **U-Net** [Ronneberger 2015] — arquitectura encoder-decoder con skip connections
 - Backbone de nuestro modelo
 - Preserva detalle espacial fino
- **CaDIS** [Grammatikopoulou 2021] — benchmark de escenas quirúrgicas de cataratas
 - Motivación del dominio
- **MedSAM / SAM-Adapter** [Ma 2024, Chen 2023] — modelos fundacionales
 - Requieren 20+ GPUs A100 y grandes volúmenes de datos
 - **No son viables** para datasets pequeños como el nuestro

- **Vaswani 2017** — “Attention is All You Need”
 - Define el mecanismo Q/K/V que adoptamos
- **mmFormer** [Zhang 2022] — transformer multimodal médico
 - Cross-attention entre modalidades de MRI
 - **Inspiración directa de nuestro módulo de fusión**
- **DECTNet** [Li 2024] — encoder dual CNN + Transformer
 - Precedente estructural: encoders paralelos con sesgos inductivos distintos

¿Dónde Encaja Nuestro Trabajo?



Arquitectura Propuesta — Vista General



■ Encoder RGB ■ Encoder bordes ■ Cross-Attention ■ Skip projections

Representaciones de Entrada

Flujo RGB

- Imagen original normalizada a $[0, 1]$
- Redimensionada a 512×512
- Captura **color, textura, fotometría**

Flujo de bordes

- Filtro Canny aplicado a escala de grises
- Resultado replicado a 3 canales
- Captura **límites geométricos**
- **Recalculado** tras cada augmentación geométrica


La clave de la dualidad
RGB y bordes son **espacios de**

features heterogéneos: uno codifica apariencia, el otro estructura. Una sola imagen produce dos representaciones complementarias.

¿Por qué recalcular Canny?

Si la imagen se rota o voltea durante augmentación y el mapa de bordes no, el modelo aprende una inconsistencia geométrica.

¿Cómo se ve el mapa de bordes Canny?



Fila superior: imágenes RGB **Fila inferior:** bordes Canny ($t_1=50$, $t_2=150$)

Los bordes del cristalino y la córnea son geoméricamente explícitos incluso cuando el contraste de color es bajo.

Encoders Duales

- Dos encoders U-Net **independientes** — misma arquitectura ResNet-34, **sin pesos compartidos**
- Cada encoder produce mapas de features en **5 resoluciones**:
 - Canales: $64 \rightarrow 64 \rightarrow 128 \rightarrow 256 \rightarrow 512$
 - Resolución espacial: $256 \rightarrow 128 \rightarrow 64 \rightarrow 32 \rightarrow 16$
- **Encoder A** procesa la imagen RGB
- **Encoder B** procesa el mapa de bordes

Clave

Los pesos separados permiten que cada encoder aprenda representaciones especializadas para su modalidad.

Módulo de Cross-Attention

Reshape: $(B, C, H, W) \rightarrow (B, HW, C)$

$$\tilde{\mathbf{F}}_A = \text{LN} \left(\alpha \cdot \text{MHA}(\underbrace{Q=\mathbf{F}_A}_{\text{RGB}}, \underbrace{K=V=\mathbf{F}_B}_{\text{bordes}}) + \mathbf{F}_A \right)$$

- **Conexión residual** ($+\mathbf{F}_A$): si la atención no ayuda, el flujo RGB pasa intacto
- **Layer Norm** estabiliza el entrenamiento
- **8 cabezas** permiten atender múltiples tipos de bordes en paralelo

¿Qué logra esto?

Los features RGB *preguntan* al mapa de bordes dónde están los contornos anatómicos y enriquecen su representación antes del decoder.

$$\alpha = \sigma(\theta), \quad \theta_0 = -4 \Rightarrow \alpha_0 \approx 0,02$$

- Al inicio: modelo casi puramente RGB
- Durante el entrenamiento: α crece **solo si los bordes ayudan**
- Si el mapa Canny es ruidoso: el gate permanece cerrado

¿Por qué es importante?

Sin el gate, los features de bordes ruidosos degradarían el rendimiento. El gate protege al modelo.

Diferencia con Early Fusion

Early Fusion fuerza ambas modalidades desde la época 1. El gate es selectivo.

Dos instancias de cross-attention:

1. **Cuello de botella** — 512 canales, resolución 16×16
2. **Etapas 4** — 256 canales, resolución 32×32


Skip connections del encoder de bordes:

$$\hat{\mathbf{F}}^{(s)} = \text{Conv}_{1 \times 1} \left(\left[\mathbf{F}_A^{(s)} \parallel \mathbf{F}_B^{(s)} \right] \right), \quad s \in \{1, 2, 3, 4\}$$

Efecto combinado

Los cues geométricos se propagan por **todo el camino de expansión**, no solo en el cuello de botella.

Flujo Completo del Modelo



Ambos encoders comparten arquitectura (ResNet-34) pero **no pesos**. El decoder recibe el bottleneck fusionado más skips de **ambos** encoders.

Configuración de Entrenamiento

Función de pérdida

$$\mathcal{L} = \mathcal{L}_{\text{BCE}} + \mathcal{L}_{\text{Dice}}$$

Penaliza errores a nivel de píxel y de solapamiento

Optimizador: AdamW

$\text{lr} = 10^{-4}$, weight decay = 10^{-2}

Schedule: 100 épocas, batch 8

Augmentación (solo entrenamiento)

- Flip horizontal ($p = 0,5$)
- Rotación ± 15
- Jitter de brillo/contraste $[0,8, 1,2]$
- Mapa de bordes **recalculado** tras transforms geométricas

Hardware: NVIDIA A100 40GB (Colab)

Semilla: 42 (todas las corridas)

Dataset: Cataract-Seg

- **Fuente:** Roboflow Universe (Muhammad Risma, 2023)
- Imágenes de segmento anterior con máscaras de píxeles
- Estructuras etiquetadas: córnea, pupila, cristalino
- **300 imágenes** en total

Partición estratificada 70/15/15:

Split	Imágenes
Entrenamiento	210
Validación	45
Test	45

Reto del dataset

300 imágenes es pequeño para segmentación médica. Los modelos fundacionales como MedSAM requieren órdenes de magnitud más datos — de ahí la apuesta por un modelo liviano sin preentrenamiento.

Augmentación geométrica y fotométrica para mitigar el tamaño reducido.

Diseño Experimental: ¿Qué Comparamos?

Cuatro modelos con **mismo backbone**, **optimizador y schedule**:

- **U-Net RGB** — baseline unimodal
- **U-Net Bordes** — Canny solo, sin color
- **Fusión Temprana** — concatenación de canales en la entrada
- **Propuesto** — encoder dual + cross-attention

La comparación es una **ablación implícita**: cada modelo aísla la contribución de una decisión de diseño.

Pregunta de investigación

¿Agrega valor la fusión por cross-attention respecto a simplemente concatenar las modalidades en la entrada?


Limitación

Sin ablación formal del gate α ni de las skip connections duales por separado.

IoU — métrica primaria

$$\text{IoU} = \frac{|\hat{M} \cap M|}{|\hat{M} \cup M|}$$

Solapamiento / área total. Penaliza FP y FN.
Reportamos el promedio sobre las 45 imágenes del test set.



Dice / F1 — métrica secundaria

$$\text{Dice} = \frac{2|\hat{M} \cap M|}{|\hat{M}| + |M|}$$

Equivalente a F1. Más sensible a solapamientos parciales que IoU.

Relación

IoU es más **conservador**: $\text{IoU} \leq \text{Dice}$.


Si $\text{IoU}=0.95$, $\text{Dice} \approx 0.974$.

Resultados Cuantitativos

Modelo	IoU	Dice/F1
U-Net (RGB)	0.9529	0.9759
U-Net (Bordes)	0.8817	0.9371
U-Net (Fusión T.)	0.9532	0.9761
Propuesto	0.9530	0.9759


- Los bordes solos confirman que Canny no es suficiente de forma independiente (IoU 0.88)
- Los 3 modelos basados en RGB están dentro de **0.0003 IoU** — ruido estadístico a $n = 45$
- El modelo propuesto **empata en primer lugar** con un mecanismo más principiado

Comparación de IoU en Test



Eje Y desde 0.85 para ampliar diferencias. La brecha principal es entre bordes solos y los modelos RGB.

Curvas de Pérdida




Pérdida BCE+Dice de entrenamiento (izq.) y validación (der.) — 100 épocas. Todos los modelos convergen sin divergencia.

IoU de Validación por Época



El modelo propuesto y Fusión Temprana siguen trayectorias paralelas. Bordes solos: meseta más baja.

Predicciones Cualitativas



Columnas: RGB — GT — U-Net RGB — U-Net Bordes — Fusión T. — **Propuesto**

Bordes solos: contornos más gruesos y ruidosos. Los modelos RGB: máscaras visualmente similares.

Tres contribuciones arquitectónicas.
Un resultado competitivo.

Conclusión: Lo que Hicimos

- Encoder dual U-Net: RGB + mapa de bordes Canny
- Cross-attention con gate aprendible en cuello de botella + etapa 4
- Skip connections del encoder de bordes en todos los niveles del decodificador

Limitaciones

- Test set de 45 imágenes — diferencias dentro del ruido estadístico

Conclusión: Lo que Logramos

- **0.9530 IoU** — empatado con el mejor baseline
- Fusión robusta al ruido gracias al gate aprendible
- Reproducible: A100, semilla 42, código en GitHub

¡Gracias!

¿Preguntas?

`github.com/DaniloDuque/multimodal-cataract-seg`